
# Documentação Projeto RCD

#### Como treinar o modelo com dataset personalizado.

1- Primeiro é a coleta de dados. É necessário tirar fotos do objeto que deseja que a IA reconheça. Em seguida, utilizamos uma ferramenta que auxilia na construção do dataset personalizado (<a href="https://roboflow.com">https://roboflow.com</a>), onde mapeamos manualmente algumas fotos (1166). Usamos um sistema de classes e é gerada uma label com coordenadas das classes "Adesivo longo", "Adesivo" e "dano". Acredito que, com outros objetos, devemos usar o dataset de adesivos junto com o dataset do outro objeto, pois quanto maior a variedade da classe "dano", melhor a IA reconhecerá o que é um dano. Tivemos uma alta confiança na classe adesivo, então não precisamos mais treinar a IA com o objeto "adesivo". Atualmente, ela identifica qualquer foto que possua "adesivo Mills" e "Mills 0800".





Para replicar, basta fazer a marcação do objeto e rotular em todas as fotos. (Obs: Temos mais de 1k fotos de adesivo com alguns danos. A IA, em muitos casos, tem mais de 90% de confiança. A ideia principal, ao trabalhar com outros objetos, seria usar o dataset de adesivos e adicionar o novo objeto, incluindo a classe desse objeto no mesmo dataset). Após isso, partimos para o passo 2.

2- Neste segundo passo, ocorre o treinamento efetivo da IA. Precisamos de muito poder computacional. Utilizamos uma plataforma do Google voltada para a comunidade de machine learning. Eles disponibilizam uma GPU para realizar esses processos. Como há limites diários, recomendo comprar alguns créditos para não perder a GPU durante o treinamento.

Usamos a biblioteca ultralytics (YOLOv8. https://github.com/ultralytics/ultralytics)

A primeira célula é para a instalação da biblioteca (!pip install ultralytics).

```
Collecting streptytics
Collecting streptytics
Collecting streptytics
Collecting streptytics
Collecting streptytics
Collecting streptytics
Requirement already satisfied an explacibility of the collection of the streptytics of the collection of the
```

A segunda célula é para a instalação do torch (!pip install torch torchvision torchaudio).

```
Requirement already satisfied: torch in /usr/local/lib/python3.10/dist-packages (2.0.1+cu118)
Requirement already satisfied: torchvision in /usr/local/lib/python3.10/dist-packages (0.15.2+cu118)
Requirement already satisfied: torchvision in /usr/local/lib/python3.10/dist-packages (2.0.2+cu118)
Requirement already satisfied: torchaudio in /usr/local/lib/python3.10/dist-packages (7.0.2+cu118)
Requirement already satisfied: filelock in /usr/local/lib/python3.10/dist-packages (from torch) (3.12.2)
Requirement already satisfied: typing-extensions in /usr/local/lib/python3.10/dist-packages (from torch) (4.7.1)
Requirement already satisfied: sympy in /usr/local/lib/python3.10/dist-packages (from torch) (4.7.1)
Requirement already satisfied: networkx in /usr/local/lib/python3.10/dist-packages (from torch) (3.1.2)
Requirement already satisfied: intion=2.0.0 in /usr/local/lib/python3.10/dist-packages (from torch) (2.0.0)
Requirement already satisfied: cmake in /usr/local/lib/python3.10/dist-packages (from torch) (2.0.0)
Requirement already satisfied: lit in /usr/local/lib/python3.10/dist-packages (from torch) (3.27.2)
Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from torchvision) (1.23.5)
Requirement already satisfied: requests in /usr/local/lib/python3.10/dist-packages (from torchvision) (2.31.0)
Requirement already satisfied: harkupSafe>2.0 in /usr/local/lib/python3.10/dist-packages (from torchvision) (2.1.3)
Requirement already satisfied: charset-normalizer
Requirement already satisfied: charset-normalizer
Requirement already satisfied: charset-normalizer
Requirement already satisfied: unlib3
Requirement already satisfied: charset-normalizer
Requirement already satisfied: charset-normalizer
Requirement already satisfied: unlib3
Requirement already satisfied: unlib3
Requirement already satisfied: charset-normalizer
Requirement already satisfied: unlib3
Requirement already satisfied: unlib3
Requirement already satisfied: unlib3
Requireme
```

A terceira célula seria para descompactar o dataset (caso não saiba como fazer, há uma pasta ao lado onde se fazem os uploads dos arquivos para o servidor do Colab) (!y | unzip /content/RCD.v8i.yolov8.zip).

```
! y | unzip /content/RCD.v8i.yolov8.zip


    /bin/bash: line 1: y: command not found

    Archive: /content/RCD.v8i.yolov8.zip
     extracting: README.dataset.txt
     extracting: README.roboflow.txt
     extracting: data.yaml
       creating: test/
       creating: test/images/
     extracting: test/images/frame_10074_jpg.rf.a1f24d9c0c227ebd76886b7bbf97025b.jpg
     extracting: test/images/frame_1022_jpg.rf.a9c25eea038dcf2e052fb16f1b0db442.jpg
     extracting: test/images/frame_10314_jpg.rf.35cacdb87a57c4b8d547b01adc7675a5.jpg
     extracting: test/images/frame_11806_jpg.rf.6de884c1513e93b44164ecf736990476.jpg
     extracting: test/images/frame_1468_jpg.rf.b151199e71efdb879e6f26b5c480b639.jpg
     extracting: test/images/frame 1504 jpg.rf.fb6b02c007cccc1b834307a50b2cbbe4.jpg
     extracting: test/images/frame_15408_jpg.rf.3122f8f806b12ccb78c4dfe9a8c7ef46.jpg
     extracting: test/images/frame_16189_jpg.rf.0c6b60404608a85576620236415eee2a.jpg
     extracting: test/images/frame_16824_jpg.rf.b38883c2f3078d9b37fda6e3706e3129.jpg
     extracting: test/images/frame_16854_jpg.rf.1d07cc86044c03d98072c5c09d460754.jpg
     extracting: test/images/frame_17009_jpg.rf.50146b8139cb9602b4ea666ef57c9f8c.jpg
     extracting: test/images/frame_17069_jpg.rf.5f594a95ff07c89fae77261413c4c8f4.jpg
extracting: test/images/frame_17911_jpg.rf.1e8a7bdc8773b2e22bc5abca9e91f849.jpg
     extracting: test/images/frame_18559_jpg.rf.1ab62876cab59ae88c3c3fd3d474f508.jpg
     extracting: test/images/frame_1858_jpg.rf.2644f672045e98239b598a3bfd0f0a4f.jpg
     extracting: test/images/frame_18739_jpg.rf.68f1a92447ecf47a70eabcf14442901b.jpg
     extracting: test/images/frame_19737_jpg.rf.ac9cf6bbddf4dda5dc1f1e9d7df541e0.jpg
     extracting: test/images/frame_1990_jpg.rf.0caeac8d8ec7096386362f5c941abb1d.jpg
     extracting: test/images/frame_20038_jpg.rf.b04b7d41965ddfa92782ee8d004d7928.jpg
     extracting: test/images/frame 240 jpg.rf.85d3b55f65b89ef51b8bba6749f50438.jpg
     extracting: test/images/frame_2764_jpg.rf.d07bc39b990b11a8db373b8c91ab4940.jpg
     extracting: test/images/frame_3233_jpg.rf.4c7797f2a20ed20b776142c46e50413d.jpg
```

Na próxima célula, fazemos a importação do torch, e o treinamento.

! yolo segment train data=data.yaml model=yolov8l-seg.yaml epochs=150 imgsz=640 batch=16

Chamamos o Yolo (yolo ) na task de treinamento de segmentação (segment train) com o nosso dataset o data.yaml esta nos arquivos do dataset (data=data.yaml) chamamos o modelo yolob8"L" segundo melhor em precisão (esta na documentação esses modelos) com a tarefa de segmentação (seg.yaml) em 150 epocas (seria a passagem completa por todo o conjunto) imgsz é o tamanho da imagem (640) e colocamos um batch de 16 (tamanho do lote seria o numero de exemplos usados em uma interação), para fazer os pesos recomendo saber sobre o basico de machine learning.



nessa celula usamos metodos de validação onde é gerado as metricas do modelo

! yolo segment val model=runs/segment/train5/weights/best.pt data=data.yaml

vai ser gerado esse arquivo best.pt na pasta wights

Aqui fazemos o teste do modelo

!yolo task=segment mode=predict model=/content/content/runs/segment/train3/weights/best.pt source=/content/images save=true save\_txt=true

chamamos a task de segmentação no modo predict e colocamos o path do nosso modelo recem treinado e escolhemos onde salvar

#### -Customizações do algoritimo

Aqui temos um algoritimo de classificação de danos, area do dano em relação ao adesvio.

```
import cv2
import os
import numpy as np
from ultralytics import YOLO
import torch
def is_inside(box1, box2):
    """Verifica se o centro de box1 está dentro de box2."""
    cx1, cy1 = (box1[0] + box1[2]) // 2, (box1[1] + box1[3]) // 2 return box2[0] <= cx1 <= box2[2] and box2[1] <= cy1 <= box2[3]
def calculate_area(box):
    x1, y1, x2, y2 = box[:4]
    return (x2 - x1) * (y2 - y1)
def calculate_damage_severity(adesivo_box, danos_inside_boxes):
    adesivo_area = calculate_area(adesivo_box)
    total_damage_area = sum([calculate_area(dano) for dano in danos_inside_boxes])
    damage_ratio = total_damage_area / adesivo_area
    if damage_ratio < 0.05:
        return "Leve"
    elif damage_ratio < 0.1:
        return "Medio"
        return "Severo"
def process_frame(frame):
    results = model(frame)
    result = results[0]
    detected_boxes = result.boxes.data.cpu().numpy()
    detected_masks = None if result.masks is None else result.masks.data.cpu().numpy()
    adesivo\_counter = 0
```

```
adesivo_longo_counter = 0
          total_danos = 0
          danos_severidade_info = []
          for i, box in enumerate(detected_boxes):
                    x1, y1, x2, y2, score, class_id = map(int, box)
                    label = class_labels[class_id]
                    if class id == 0 or class id == 1:
                             \label{loss_decomposition} danos\_inside\_boxes = [dano\_box \ for \ dano\_box \ in \ detected\_boxes \ if \ int(dano\_box[5]) == 2 \ and \ is\_inside(dano\_box[:4], \ box[:4])]
                             severity = calculate_damage_severity(box, danos_inside_boxes)
                             danos_inside = len(danos_inside_boxes)
                             if class id == 0:
                                      label += f"-{adesivo_longo_counter} tem {danos_inside} danos com severidade {severity}"
                                       adesivo longo counter += 1
                             else:
                                       label += f"-{adesivo_counter} tem {danos_inside} danos com severidade {severity}"
                                       adesivo_counter += 1
                             total_danos += danos_inside
                             danos_severidade_info.append((danos_inside, severity))
                    if detected_masks is not None:
                             mask = detected masks[i]
                             mask_resized = cv2.resize(mask, (frame.shape[1], frame.shape[0]))
                             overlay = frame.copy()
                             overlay[mask_resized > 0.5] = segmentation_color[:3]
                             alpha = 0.5
                             frame = cv2.addWeighted(overlay, alpha, frame, 1 - alpha, 0)
                    cv2.rectangle(frame, (x1, y1), (x2, y2), box_color, box_thickness)
                    cv2.putText(frame, label, (x1, y1 - 10), text_font, text_size, text_color, text_thickness)
          return frame, total_danos, danos_severidade_info
torch.set_default_tensor_type('torch.FloatTensor')
model = YOLO(weights_path)
folder\_path = r'C:\label{folder\_path} = r'
save\_folder = r'C: \label{eq:save_folder} S.A \label{eq:folder} S.A \label{eq:
os.makedirs(save_folder, exist_ok=True)
class_labels = {
        0: "Adesivo Longo",
         1: "Adesivos",
          2: "dano"
}
box_color = (2,64,195)
text_color = (255,255,255)
segmentation\_color = (33, 112, 243)
box_thickness = 2
text_font = cv2.FONT_HERSHEY_PLAIN
text_size = 1.2
#text_size = 3
text thickness = 2
for filename in os.listdir(folder_path):
          file_path = os.path.join(folder_path, filename)
          save_path = os.path.join(save_folder, filename)
          if filename.endswith('.jpg') or filename.endswith('.png'):
                   image = cv2.imread(file_path)
                    processed_image, total_danos, danos_severidade_info = process_frame(image)
                    cv2.imwrite(save_path, processed_image)
                    print(f"Imagem processada salva em {save_path}")
                    print(f"Total de danos na imagem: {total_danos}")
                    for i, (qtd, severity) in enumerate(danos_severidade_info):
                             print(f"Adesivo {i+1}: Quantidade de danos: {qtd}, Severidade: {severity}")
          elif filename.endswith('.MOV') or filename.endswith('.mp4'):
                    cap = cv2.VideoCapture(file_path)
                    fourcc = cv2.VideoWriter_fourcc(*'mp4v')
```

```
out = cv2.VideoWriter(save_path, fourcc, 30.0, (int(cap.get(3)), int(cap.get(4))))
while(cap.isOpened()):
    ret, frame = cap.read()
    if ret:
        processed_frame, _, _ = process_frame(frame)
        out.write(processed_frame)
    else:
        break

cap.release()
out.release()
print(f"Video processado salvo em {save_path}")
```

# 1. is\_inside(box1, box2)

Objetivo: Verifica se o centro de box1 está localizado dentro do box2

#### Entradas:

box1 e box2: Array que representam bounding boxes no formato [x1, y1, x2, y2], onde (x1,y1) é o canto superior esquerdo e (x2,y2) é o canto inferior direito.

#### Retorno:

• Retorna True se o centro de box1 estiver dentro de box2. Caso contrário, retorna False.

# 2. calculate\_area(box)

Objetivo: Calcula a área de um bounding box.

#### Entrada:

• box: Representando um bounding box no formato [x1, y1, x2, y2].

#### Retorno:

• A área do bounding box.

#### 3. calculate\_damage\_severity(adesivo\_box, danos\_inside\_boxes)

Objetivo: Determinar a severidade do dano com base na relação entre a área do dano e a área do adesivo.

# Entradas:

- adesivo\_box: Bounding box do adesivo.
- danos\_inside\_boxes: Uma lista de bounding boxes de danos dentro do adesivo.

#### Retorno:

• Uma string indicando a severidade do dano: "Leve", "Medio" ou "Severo".

# 4. process\_frame(frame)

**Objetivo**: Processar cada frame de uma imagem ou vídeo, realizar a detecção de objetos usando o modelo YOLO, classificar e anotar os adesivos com danos e, se disponíveis, sobrepor as máscaras de segmentação na imagem.

# Entrada:

• frame: Uma imagem ou um frame de vídeo.

#### Retorno:

- frame: O frame processado com anotações.
- total\_danos: O número total de danos detectados no frame.

ad	lesivo.			

• danos\_severidade\_info: Uma lista de tuplas, onde cada tupla contém a quantidade de danos e a severidade associada a cada